

SQL

基础：选择select；表连接join/left join/union

常用：去重distinct；聚合max/min/sum/count/group by；筛选having/where；排序order by/sort by；条件case when...end；字符串substr/concat/split

进阶：日期函数to_date/dateoff；分组排除row_number()；取百分比percentile

高级：窗口函数（分组排序row_number/rank/dense_rank；分组取最大最小first_value/last_value；累积百分比cume_dist/sum()over；错位lead/lag）；日期函数（时间和日期戳转化unix_timestamp/from_unixtime；日期操作to_date/datesub/date_add/dateoff）；字符串函数（substr,concat,concat_ws,length,upper这类基础函数；regexp_replace正则/get_json_object）；其他常用函数（lateral view explode行列转换；rand等随机抽样）

SQL是一种操作数据库的语言，主要包括CRUD，对于数据分析师来说，一般只要查找数据的，不能对数据库进行增删改

```
1 SELECT columns_name --查找一列或多列之间用逗号隔开
2 FROM Table          --目标表
3 WHERE condition     --过滤条件
4 GROUP BY columns_name --按列值分组，可以1个或多个列
5 HAVING condition    --分组后的筛选条件，HAVING和WHERE的区别在于前者表达式中可包含函数
6 ORDER BY columns_name --按列排序
7 LIMIT start,row_count --对结果进行限定，start表示从哪行开始，row_count表示结果行数
```

一、基础用法

1.简单查询

2.条件查询

有一张学生表student，包括学生id，姓名，年龄，班级，分数段，下面用SQL来查找数据吧。

stu_id	stu_name	age	class	grade
1	小明	17	1	60
2	小花	18	2	90
3	小王	16	2	70
4	小李	20	1	20
5	小陈	17	2	60
6	小赵	15	1	80

student表

```
1 --查找id.姓名,成绩列
2 SELECT stu_id,stu_name,grade FROM student;
```

执行结果

信息	结果1	概况	状态
stu_id	stu_name	grade	
1	小明	60	
2	小花	90	
3	小王	70	
4	小李	20	
5	小陈	60	
6	小赵	80	

```
1 --查找成绩大于70分的学生id,姓名,成绩列
2 SELECT s.stu_id,s.stu_name,s.grade FROM student s WHERE s.grade >=70;
```

执行结果

信息	结果1	概况	状态
stu_id	stu_name	grade	
2	小花	90	
3	小王	70	
6	小赵	80	

3.聚合函数

```
1 --计算班级人数,平均成绩,最高成绩,最低成绩
2 SELECT s.class,COUNT(s.stu_id) as
count1,AVG(s.grade),MAX(s.grade),MIN(s.grade) FROM student s GROUP BY s.class;
```

执行结果

信息	结果1	概况	状态	
class	count1	AVG(s.grade)	MAX(s.grade)	MIN(s.grade)
▶ 1	3	53.333333333333336	80	20
2	3	73.33333333333333	90	60

注释：计算班级平均成绩用到了group by语句，同样的class被分为一组。当使用分组语句时，select 语句后面只能出现分组字段和聚合函数。

4.分组后筛选

```

1  --Having语句筛选班级平均分大于60分的班级
2  SELECT s.class,COUNT(s.stu_id) as
   count1,AVG(s.grade),MAX(s.grade),MIN(s.grade) FROM student s GROUP BY s.class
   HAVING AVG(s.grade)>60;

```

执行结果

信息	结果1	概况	状态	
class	count1	AVG(s.grade)	MAX(s.grade)	MIN(s.grade)
▶ 2	3	73.33333333333333	90	60

5.模糊查询

```

1  --like进行模糊匹配
2  where name like '陈%'      --找出姓陈的人
3  where name like '%铭%'    --找出名字中有铭字的人
4  where name like '陈_'     --找出姓陈且名字为两个字的人

```

注释：like进行模糊匹配时，%可以匹配任意多个任意字符，_匹配任意一个字符。

二、表连接

表连接是指两张表可以通过想用的关键字段进行连接，包括内连接和外连接。外连接包括左外连接、右外连接和全外连接。

- 1.内连接指结果表只包含同时存在两张表中的连接字段
- 2.左外连接是指既包含内连接的连接字段还包含左表未连接的字段
- 3.右外连接是指既包含内连接的连接字段还包含右表未连接的字段
- 4.全外连接是指包含两张表的所有连接字段.

韦恩图



知乎 @呆呆玩数据

从左到右，依次是内连接，左外连接，右外连接，全外连接

表连接，两张表student, student2, stu_id为连接字段

对象	student @数据分析 (localhos...	* 无标题 @数		
开始事务	备注	筛选		
排序				
stu_id	stu_name	age	class	grade
1	小明	17	1	60
2	小花	18	2	90
3	小王	16	2	70
4	小李	20	1	20
5	小陈	17	2	60
6	小赵	15	1	80

student2 @数据分析 (localhost_3306) - 表	
文件 编辑 查看 窗口 帮助	
开始事务 备注 筛选 排序 导入	
stu_id	gender
1	1
2	0
3	1
4	1
8	0
9	0

1.内连接

```
1 -- 内连接，*是通配符，取出表中所有变量
2 SELECT s1.*,s2.* FROM student s1 INNER JOIN student2 s2 ON
   s1.stu_id=s2.stu_id;
```

执行结果

<						
信息	结果1	概况	状态			
stu_id	stu_name	age	class	grade	stu_id1	gender
1	小明	17	1	60	1	1
2	小花	18	2	90	2	0
3	小王	16	2	70	3	1
4	小李	20	1	20	4	1
(Null)	(Null)	(Null)	(Null)	(Null)	8	0
(Null)	(Null)	(Null)	(Null)	(Null)	9	0

4.全外连接

```

1  -- 全外连接
2  SELECT
3      *
4  FROM
5      student s1
6  LEFT JOIN student2 s2 ON s1.stu_id = s2.stu_id
7  UNION
8      SELECT
9          *
10     FROM
11         student s1
12     RIGHT JOIN student2 s2 ON s1.stu_id = s2.stu_id;

```

执行结果

数据分析

表

student

student2

视图

函数

事件

查询

数据分析

报表

备份

modishou_online

外网访问本地服务器

```

12
13 SELECT s1.*,s2.* FROM student s1 RIGHT JOIN student2 s2 ON s1.stu_id
14
15 -- 全外链接
16 SELECT
17 *
18 FROM
19 student s1
20 LEFT JOIN student2 s2 ON s1.stu_id = s2.stu_id
21 UNION
22 SELECT
23 *
24 FROM
25 student s1
26 RIGHT JOIN student2 s2 ON s1.stu_id = s2.stu_id;
27
28
29

```

信息

结果1

概况

状态

stu_id	stu_name	age	class	grade	stu_id1	gender
1	小明	17	1	60	1	1
2	小花	18	2	90	2	0
3	小王	16	2	70	3	1
4	小李	20	1	20	4	1
5	小陈	17	2	60	(Null)	(Null)
6	小赵	15	1	80	(Null)	(Null)
(Null)	(Null)	(Null)	(Null)	(Null)	8	0
(Null)	(Null)	(Null)	(Null)	(Null)	9	0

三、子查询

子查询是指把一个查询的结果放到另一个查询里面使用，功能十分丰富，既可以放在from语句中作为临时表供另一个查询使用，也可以放在where语句子句后面进行过滤。

放在where子句后面的子查询返回结果可以是单行，也可以是多行。

单行子查询一般与>,<=,<,>=等比较符一起使用。

而多行子查询与in(等于子查询返回结果的任意一个)，any(比较符满足子查询中的任意一个情况)，all(比较符满足子查询中所有情况)等配套使用

1.where单行子查询

student表中查询grade大于平局分的学生id，姓名，分数

```

1  -- where单行子查询
2  SELECT
3      s.stu_id,
4      s.stu_name,
5      s.grade
6  FROM
7      student s
8  WHERE
9      s.grade > (
10         SELECT
11             AVG(s.grade)
12         FROM
13             student s

```

执行结果

```

28 -- where单行子查询,student表中查询grade大于平均分(73.33)的学生id, 分数
29 SELECT
30     s.stu_id,
31     s.stu_name,
32     s.grade
33 FROM
34     student s
35 WHERE
36     s.grade > (
37         SELECT
38             AVG(s.grade)
39         FROM
40             student s
41     )

```

信息	结果1	概况	状态
stu_id	stu_name	grade	
2	小花	90	
3	小王	70	
6	小赵	80	

2.where/from多行子查询

```

1  -- student表中查询属于班级平均分最高班级的学生信息
2  SELECT
3      s.stu_id,
4      s.stu_name,
5      s.grade,
6      s.class
7  FROM
8      student s
9  WHERE
10     s.class IN (
11         SELECT
12             class
13         FROM
14             (
15                 SELECT
16                     class,
17                     AVG(grade) avg_grade
18                 FROM
19                     student
20                 GROUP BY
21                     class
22                 ORDER BY
23                     AVG(grade) DESC
24                 LIMIT 1
25             ) sub_1
26     )

```


执行结果

```
29
30 -- student表中查询属于班级平均分最高班级的学生信息
31 SELECT
32     s.stu_id,
33     s.stu_name,
34     s.grade,
35     s.class
36 FROM
37     student s
38 WHERE
39     s.class IN (
40         SELECT
41             class
42         FROM
43             (
44                 SELECT
45                     class,
46                     AVG(grade) avg_grade
47                 FROM
48                     student
49                 GROUP BY
50                     class
51                 ORDER BY
52                     AVG(grade) DESC
53                 LIMIT 1
54             ) sub_1
55     )
```

信息	结果1	概况	状态
----	-----	----	----

stu_id	stu_name	grade	class
2	小花	90	2
3	小王	70	2
5	小陈	60	2

上面这个嵌套子查询，一共用了两层子查询：

首先最里层的子查询计算了每个班级的平均分，然后用order by子句按班级平均分倒序排列(最高分排第一个)，然后limit 1限制输出一行数据，得到了最高分的班级行，接着把这层子查询的结果放到外面一层子查询的from语句后面。

第二层子查询得到class，最后外查询的where子句判断class是不是等于第二层子查询中的某一个

3.all

```
1 -- student表中最高分的学生信息
2 SELECT * from student s WHERE s.grade>=ALL(SELECT s.grade FROM student s)
```

执行结果

```

68 -- student表中中的最高分的学生信息
69 SELECT * from student s WHERE s.grade>=ALL(SELECT s.grade FROM student s)

```

信息	结果1	概况	状态		
stu_id	stu_name	age	class	grade	
2	小花	18	2	90	

4.any

```

1 -- student表中非最低分的学生信息
2 SELECT * from student s WHERE s.grade>ANY(SELECT s.grade FROM student s)

```

执行结果

```

70 -- student表中非最低分的学生信息
71 SELECT * from student s WHERE s.grade>ANY(SELECT s.grade FROM student s)

```

信息	结果1	概况	状态	
stu_id	stu_name	age	class	grade
▶	1 小明	17	1	60
	2 小花	18	2	90
	3 小王	16	2	70
	5 小陈	17	2	60
	6 小赵	15	1	80

注释：只有最低分的学生成绩不大于任何一个人的分数，被排除在外

四、case when

case when语句是sql中的一个非常重要的功能，可以完成很多复杂的计算，相当于一个表达式。可以放在任何可放表达式的地方。

语法：

case when 条件 then 结果 when 条件 then 结果 else end

else可不加，是缺省条件下的值，如果不加，有缺省情况则为null。

case when还可以和group by语句搭配使用，用在sum，count，max等聚合函数内部

1.例1

查询结果中，student表中生成一个新字段“成绩等级grade_level”，小于60分不及格，大于等于60小于80及格，大于等于80小于90良好，大于等于90优秀

```

1 SELECT
2     s.*, (
3     CASE

```

```

4      WHEN s.grade < 60 THEN
5          '不及格'
6      WHEN s.grade >= 60
7      AND s.grade < 80 THEN
8          '及格'
9      WHEN s.grade >= 80
10     AND s.grade < 90 THEN
11         '良好'
12     WHEN s.grade >= 90 THEN
13         '优秀'
14     END
15 ) grade_level
16 FROM
17     student s

```

执行结果

-- 查询结果中，student表中生成一个新字段“成绩等级grade_level”，小于60分不及格，大于等于60小于80及格，大于等于80小于90良好，大于等于90优秀

```

72 SELECT
73     s.*, (
74     CASE
75     WHEN s.grade < 60 THEN
76         '不及格'
77     WHEN s.grade >= 60
78     AND s.grade < 80 THEN
79         '及格'
80     WHEN s.grade >= 80
81     AND s.grade < 90 THEN
82         '良好'
83     WHEN s.grade >= 90 THEN
84         '优秀'
85     END
86     ) grade_level
87 FROM
88     student s
89

```

stu_id	stu_name	age	class	grade	grade_level
1	小明	17	1	60	及格
2	小花	18	2	90	优秀
3	小王	16	2	70	及格
4	小李	20	1	20	不及格
5	小陈	17	2	60	及格
6	小赵	15	1	80	良好

2.例2

计算每个班级中，及格和不及格的人数

```

1  SELECT
2      s.class,
3      COUNT(
4          CASE
5              WHEN s.grade < 60 THEN
6                  s.stu_id
7          END
8      ) failed_num,
9      COUNT(
10         CASE
11             WHEN s.grade >= 60 THEN
12                 s.stu_id
13         END

```

```

14      ) pass_num
15  FROM
16      student s
17  GROUP BY
18      s.class

```

执行结果

```

90  -- 计算每个班级中，及格和不及格的人数
91  SELECT
92      s.class,
93      COUNT(
94          CASE
95              WHEN s.grade < 60 THEN
96                  s.stu_id
97          END
98      ) failed_num,
99      COUNT(
100         CASE
101             WHEN s.grade >= 60 THEN
102                 s.stu_id
103         END
104     ) pass_num
105  FROM
106      student s
107  GROUP BY
108      s.class

```

class	failed_num	pass_num
1	1	2
2	0	3

五、组合查询

sql中可用union或union all将多个查询结果拼接起来，两者的区别是union会对结果重新排序，而union all不会，所以一般为了节省内存在不需要排序的情况下用union all更好

eg.

```

1  -- 组合查询，查询两个班都及格的学生信息
2  SELECT * FROM student s1 WHERE s1.grade >=60 ORDER BY s1.class ASC
3
4  SELECT * FROM student s1 WHERE s1.class=1 AND s1.grade>=60
5  UNION ALL
6  SELECT * FROM student s1 WHERE s1.class=2 AND s1.grade>=60

```

执行结果

```

109 -- 查询两个班都及格的学生信息
110 SELECT * FROM student s1 WHERE s1.grade >=60 ORDER BY s1.class ASC
111
112 SELECT * FROM student s1 WHERE s1.class=1 AND s1.grade>=60
113 UNION ALL
114 SELECT * FROM student s1 WHERE s1.class=2 AND s1.grade>=60

```

信息	结果1	概况	状态	
stu_id	stu_name	age	class	grade
1	小明	17	1	60
6	小赵	15	1	80
2	小花	18	2	90
3	小王	16	2	70
5	小陈	17	2	60

六、常用函数

```

1 -- 字符串函数
2 -- 截取字符串string, 从start开始的length个字符, 类似excel的mid
3 substring(string,start,length)
4 -- 截取字符串string, 从最左边开始的length个字符, 类似excel的left
5 left(string,length)
6 -- 截取字符串string, 从最右边开始的length个字符, 类似excel的right
7 right(string,length)
8 -- mysql中查找string1在string2中出现的位置
9 instr(string1,string2[start_location])
10 -- mysql中删除指定个数字符, 并在指定位置处插入新字符
11 insert(string1,start,length,string2)

```

eg.

```

1 SELECT
2     substring(
3         '中国浙江省杭州市',
4         3,
5         3
6     ) AS province,
7     LEFT (
8         '中国浙江省杭州市',
9         2
10    ) AS country,
11    RIGHT (
12        '中国浙江省杭州市',
13        3
14    ) AS city,
15    instr(
16        '中国浙江省杭州市',
17        '杭州市'
18    ) AS index_city,

```

```

19      INSERT (
20          '中国浙江省杭州市',
21          6,
22          3,
23          '宁波市'
24      ) AS replace_city

```

执行结果

```

115
116 SELECT
117     substring(
118         '中国浙江省杭州市',
119         3,
120         3
121     ) AS province,
122     LEFT (
123         '中国浙江省杭州市',
124         2
125     ) AS country,
126     RIGHT (
127         '中国浙江省杭州市',
128         3
129     ) AS city,
130     instr(
131         '中国浙江省杭州市',
132         '杭州市'
133     ) AS index_city,
134     INSERT (
135         '中国浙江省杭州市',
136         6,
137         3,
138         '宁波市'
139     ) AS replace_city

```

<				
信息	结果1	概况	状态	
province	country	city	index_city	replace_city
▶ 浙江省	中国	杭州市	6	中国浙江省宁波市

七、日期函数

```

1  -- 日期函数，不同数据库会有一些区别，此处以mysql为例
2  -- 当前日期
3  current_date()
4  -- date加减expr的unit (年月日周) 的date
5  date_add(date,interval expr unit)
6  -- expr1减去expr2的天数
7  datediff(expr1,expr2)
8  -- expr1减去expr2的时间
9  timediff(expr1,expr2)
10 --格式化日期
11 date_format(date,format)
12 -- 将字符转换成日期
13 str_to_date(str,format)

```

eg.

```

1  SELECT
2      CURRENT_DATE () AS now,
3      date_add(
4          CURRENT_DATE (),
5          INTERVAL - 1 DAY
6      ) AS yesterday,
7      datediff(
8          CURRENT_DATE (),
9          DATE_ADD(
10             CURRENT_DATE (),
11             INTERVAL - 1 DAY
12         )
13     ) AS date_cha,
14     date_format(CURRENT_DATE(), '%Y/%m') AS ym,
15     str_to_date('2020-07-02', '%Y-%m-%d') AS strdate

```

执行结果

对象		数据分析 @数据分析 (localho...			student_new @数据分析 (loc...	
		开始事务			备注	
		筛选			排序	
		导入			导出	
stu_id	stu_name	age	class	grade		
1	小明	17	1	60		
2	小花	18	2	90		
3	小王	16	2	70		
4	小李	20	1	20		
5	小陈	17	2	60		
6	小赵	15	1	80		
7	小钱	17	1	90		
8	小冯	19	2	90		
9	小孙	17	1	80		
10	小周	18	2	70		

执行结果

```
157
158 -- 用于排序, row_number,rank,dense_rank mysql8.0支持窗口函数
159 SELECT a.*,
160 row_number() over(PARTITION by class order by grade desc)as row_num,
161 rank() over(PARTITION by class order by grade desc)as rank_num,
162 dense_rank() over(PARTITION by class order by grade desc)as dense_num,
163 FROM student_new a;-- 这里会报错
164
165 -- 用union实现排序
166 SELECT * FROM
167 (SELECT * FROM student_new a WHERE a.class=1 ORDER BY a.grade) a1
168 UNION ALL
169 SELECT * FROM
170 (SELECT * FROM student_new a WHERE a.class=2 ORDER BY a.grade) a2; -- order by不能直接出现在union的子句中, 但是可以出现在子句的子句中
```

信息	结果1	概况	状态	
stu_id	stu_name	age	class	grade
4	小李	20	1	20
1	小明	17	1	60
6	小赵	15	1	80
9	小孙	17	1	80
7	小钱	17	1	90
5	小陈	17	2	60
3	小王	16	2	70
10	小周	18	2	70
2	小花	18	2	90
8	小马	19	2	90

【举个栗子_12】窗口函数-排序

```
--用于排序, row_number, rank, dense_rank  
SELECT a.*,  
       row_number() over(partition by class order by grade desc) as row_num,  
       rank() over(partition by class order by grade desc) as rank_num,  
       dense_rank() over(partition by class order by grade desc) as dense_num,  
FROM student_new a
```

stu_id	stu_name	age	class	grade	row_num	rank_number	dense_rank
7	小钱	17	1	90	1	1	1
6	小赵	15	1	80	2	2	2
9	小孙	17	1	80	3	2	2
1	小明	17	1	60	4	4	3
4	小李	20	1	20	5	5	4
2	小花	18	2	90	1	1	1
8	小冯	19	2	90	2	1	1
3	小王	16	2	70	3	3	2
10	小周	18	2	70	4	3	2
5	小陈	17	2	60	5	5	3

由上面这个例子可以清晰地看出三个窗口排序函数的区别, row_number是在每个分组窗口中给定唯一序号, 而rank碰到相等值序号一样, 会跳过之后的位次, 而dense_rank碰到相等值序号也一致, 但不跳过之后的位次。